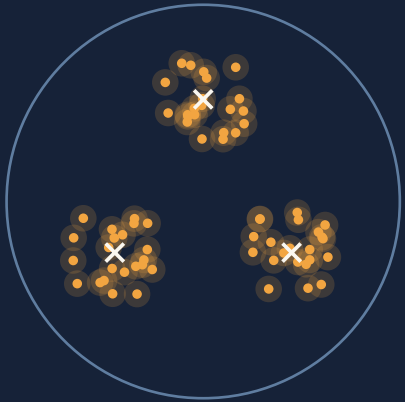
No culpes a k-medias,

no culpes a los centros,
no culpes a los datos:
será que es la distancia.

Pablo Groisman

DM Exactas-UBA e IMAS-UBA/CONICET

Dátame! – 2026



1

Los datos (versión empírica)



El problema: agrupar datos

Problema. Tenemos n datos $\{x_1, \ldots, x_n\} \subset \mathbb{R}^\ell$ y un entero k. Queremos partirlos en k grupos disjuntos $\{C_1, \ldots, C_k\}$.

El problema: agrupar datos

Problema. Tenemos n datos $\{x_1, \ldots, x_n\} \subset \mathbb{R}^\ell$ y un entero k. Queremos partirlos en k grupos disjuntos $\{C_1, \ldots, C_k\}$.

El problema: agrupar datos

Problema. Tenemos n datos $\{x_1, \ldots, x_n\} \subset \mathbb{R}^\ell$ y un entero k. Queremos partirlos en k grupos disjuntos $\{C_1, \ldots, C_k\}$.



© MNIST Dataset

El problema: agrupar datos

Problema. Tenemos n datos $\{x_1, \ldots, x_n\} \subset \mathbb{R}^\ell$ y un entero k. Queremos partirlos en k grupos disjuntos $\{C_1, \ldots, C_k\}$.



© MNIST Dataset

Ejemplo: MNIST.

El problema: agrupar datos

Problema. Tenemos n datos $\{x_1, \ldots, x_n\} \subset \mathbb{R}^\ell$ y un entero k. Queremos partirlos en k grupos disjuntos $\{C_1, \ldots, C_k\}$.



© MNIST Dataset

Ejemplo: MNIST.

- 70.000 dígitos escritos a mano.

El problema: agrupar datos

Problema. Tenemos n datos $\{x_1, \ldots, x_n\} \subset \mathbb{R}^\ell$ y un entero k. Queremos partirlos en k grupos disjuntos $\{C_1, \ldots, C_k\}$.



© MNIST Dataset

Ejemplo: MNIST.

- 70.000 dígitos escritos a mano.
- Cada imagen tiene 28×28 píxeles: es un punto de $\mathbb{R}^{784}$.

El problema: agrupar datos

Problema. Tenemos n datos $\{x_1, \ldots, x_n\} \subset \mathbb{R}^\ell$ y un entero k. Queremos partirlos en k grupos disjuntos $\{C_1, \ldots, C_k\}$.



© MNIST Dataset

Ejemplo: MNIST.

- 70.000 dígitos escritos a mano.
- Cada imagen tiene 28×28 píxeles: es un punto de $\mathbb{R}^{784}$.
- Sin mirar las etiquetas, ¿podemos armar $k = 10$ grupos, uno por dígito?

La solución de k-medias

Elegir k centros que minimicen la varianza dentro de cada grupo:

$$W_n = \{m_1, \ldots, m_k\} := \arg\min_{A \subseteq \mathbb{R}^\ell, |A| \leq k} \frac{1}{n} \sum_{i=1}^{n} \min_{m \in A} \|x_i - m\|^2$$

La solución de k-medias

Elegir k centros que minimicen la varianza dentro de cada grupo:

$$W_n = \{m_1, \ldots, m_k\} := \arg\min_{A \subseteq \mathbb{R}^\ell, |A| \leq k} \frac{1}{n} \sum_{i=1}^{n} \min_{m \in A} \|x_i - m\|^2$$

y a cada punto lo mandamos al grupo del centro más cercano:

$$C_r = \{x \colon \|x - m_r\| = \min_{1 \leq j \leq k} \|x - m_j\|\}.$$

La solución de k-medias

Elegir k centros que minimicen la varianza dentro de cada grupo:

$$W_n = \{m_1, \ldots, m_k\} := \arg\min_{A \subseteq \mathbb{R}^\ell, |A| \leq k} \frac{1}{n} \sum_{i=1}^{n} \min_{m \in A} \|x_i - m\|^2$$

y a cada punto lo mandamos al grupo del centro más cercano:

$$C_r = \{x \colon \|x - m_r\| = \min_{1 \leq j \leq k} \|x - m_j\|\}.$$

Para $k = 1$ la solución es el promedio: $m_1 = \frac{1}{n} \sum_{i=1}^{n} x_i$.

El algoritmo (Lloyd)

1. Elegir k centros iniciales (al azar, o con k-means++).

El algoritmo (Lloyd)

1. Elegir k centros iniciales (al azar, o con k-means++).
2. **Asignar:** cada punto va al grupo del centro más cercano.

El algoritmo (Lloyd)

1. Elegir k centros iniciales (al azar, o con k-means++).
2. **Asignar:** cada punto va al grupo del centro más cercano.
3. **Actualizar:** cada centro pasa a ser el *promedio* de su grupo.

El algoritmo (Lloyd)

1. Elegir k centros iniciales (al azar, o con k-means++).
2. **Asignar:** cada punto va al grupo del centro más cercano.
3. **Actualizar:** cada centro pasa a ser el *promedio* de su grupo.
4. Repetir 2 y 3 hasta que nada cambie.

El algoritmo (Lloyd)

1. Elegir k centros iniciales (al azar, o con k-means++).
2. **Asignar:** cada punto va al grupo del centro más cercano.
3. **Actualizar:** cada centro pasa a ser el *promedio* de su grupo.
4. Repetir 2 y 3 hasta que nada cambie.

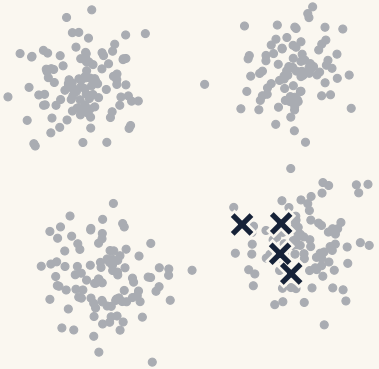
El algoritmo (Lloyd)

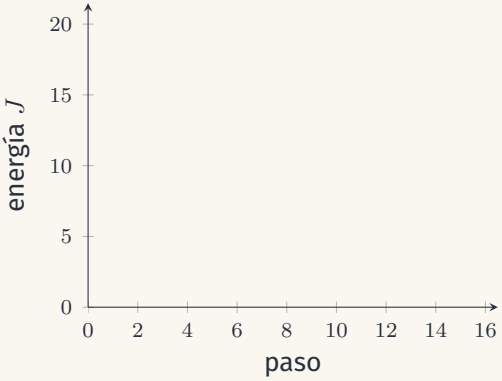
1. Elegir k centros iniciales (al azar, o con k-means++).
2. **Asignar:** cada punto va al grupo del centro más cercano.
3. **Actualizar:** cada centro pasa a ser el *promedio* de su grupo.
4. Repetir 2 y 3 hasta que nada cambie.

Sencillo, rápido e interpretable.

Lloyd en acción

Centros iniciales

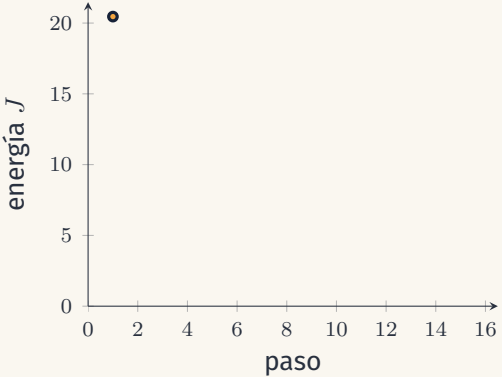




Lloyd en acción

Iteración 1: asignar

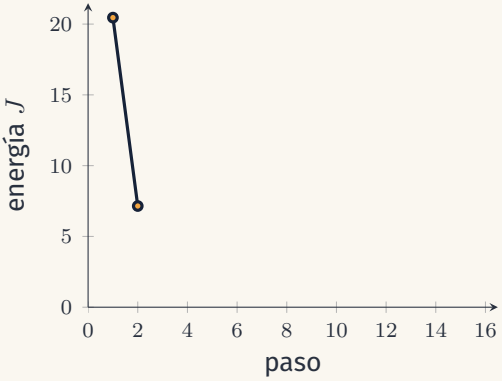




Lloyd en acción

Iteración 1: actualizar

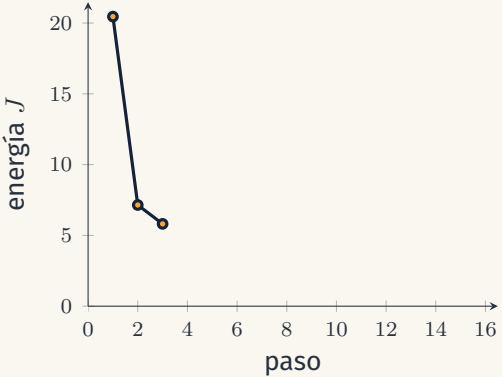




Lloyd en acción

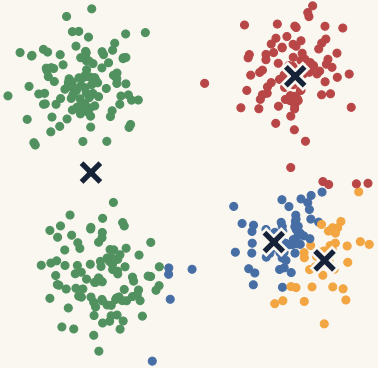
Iteración 2: asignar

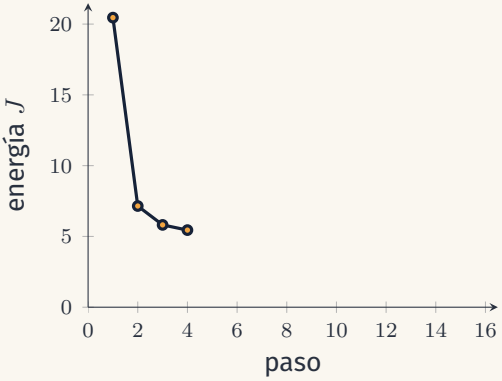




Lloyd en acción

Iteración 2: actualizar

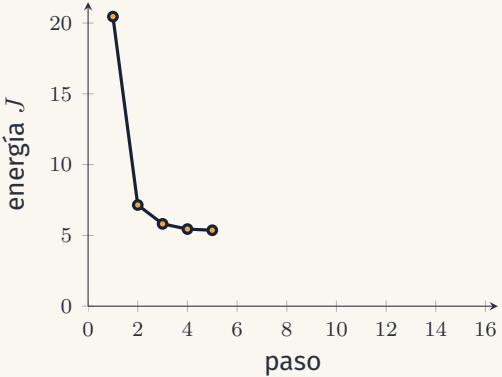




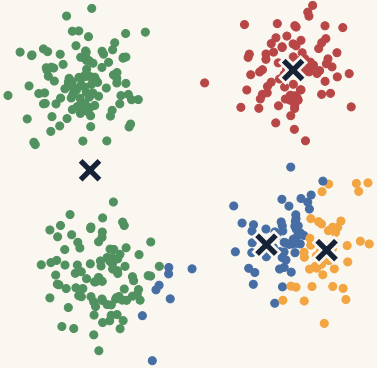
Lloyd en acción

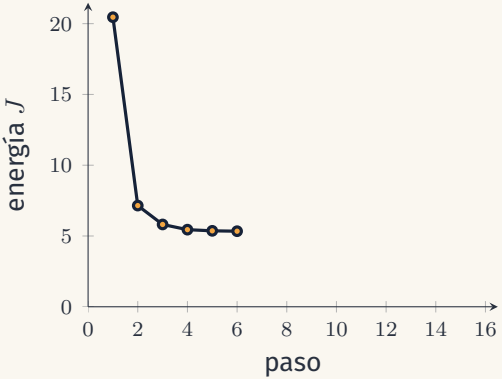
Iteración 3: asignar



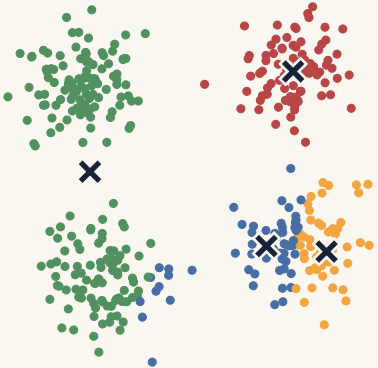


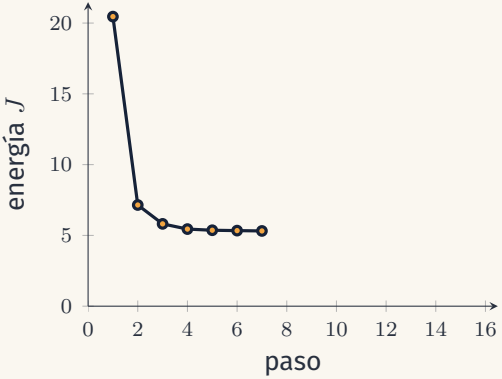
Lloyd en acción





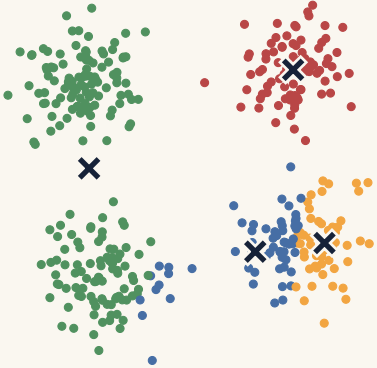
Lloyd en acción

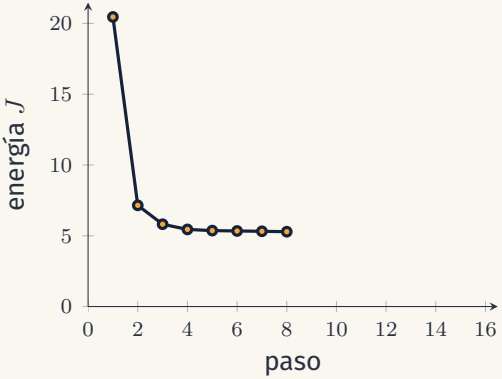




Lloyd en acción

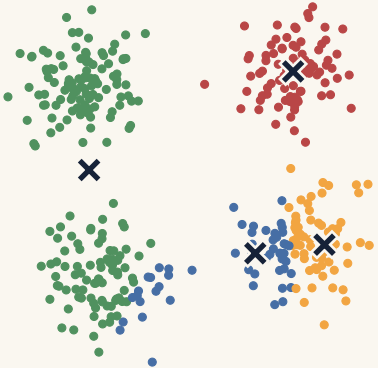
Iteración 4: actualizar

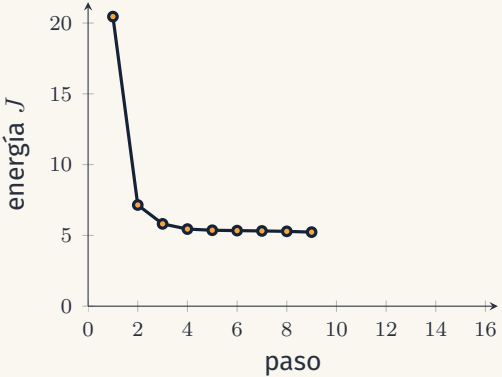




Lloyd en acción

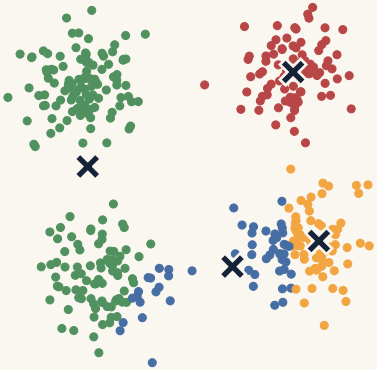
Iteración 5: asignar

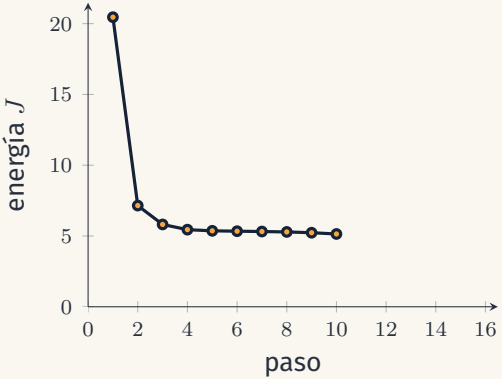




Lloyd en acción

Iteración 5: actualizar

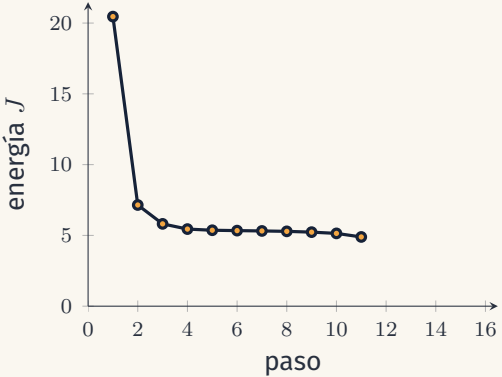




Lloyd en acción

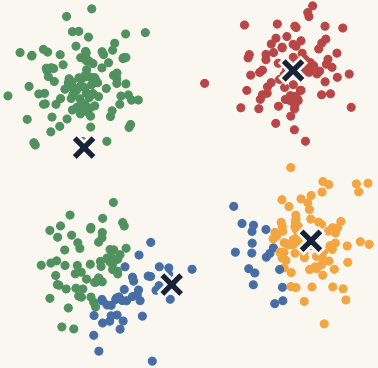
Iteración 6: asignar

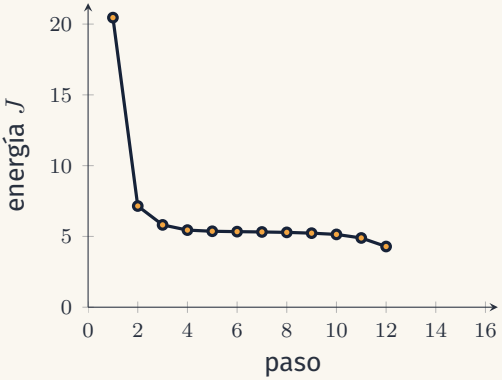




Lloyd en acción

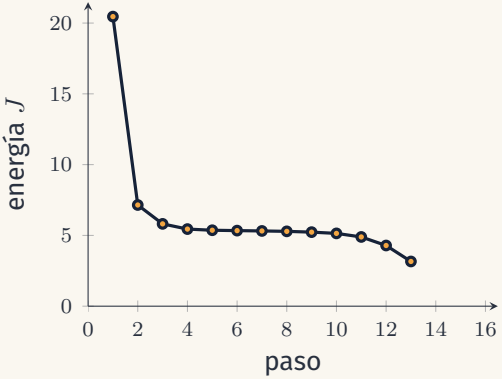
Iteración 6: actualizar





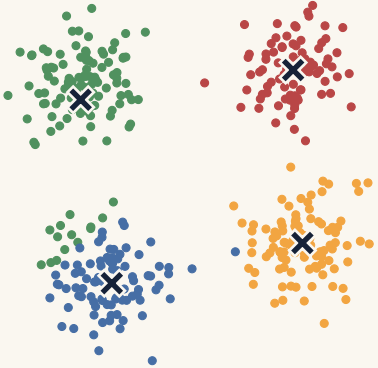
Lloyd en acción

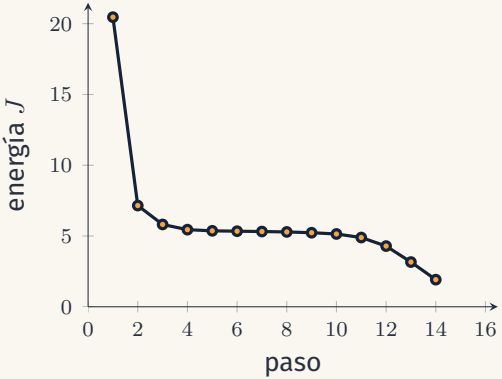




Lloyd en acción

Iteración 7: actualizar

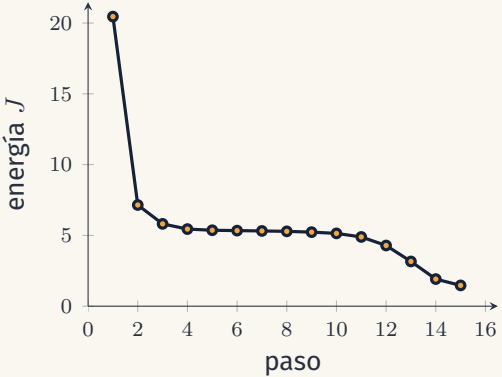




Lloyd en acción

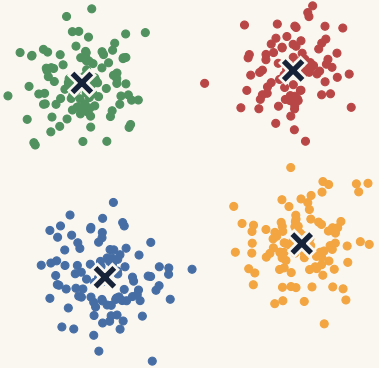


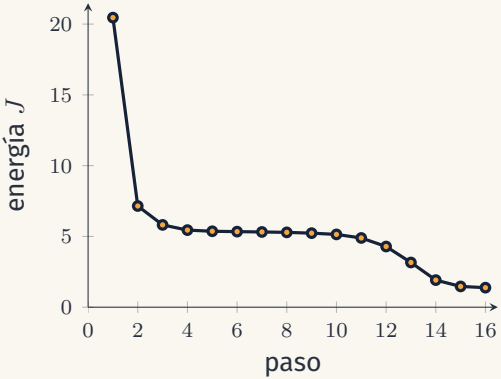
Iteración 8: asignar



Lloyd en acción

Iteración 8: actualizar





2

Las variables aleatorias (versión poblacional)



Antes un repaso...

X un vector aleatorio en $\mathbb{R}^\ell$ con $\mathbb{E}\|X\|^2 < \infty$, y $m = \mathbb{E}(X)$. Para todo $a \in \mathbb{R}^\ell$:

Antes un repaso...

X un vector aleatorio en $\mathbb{R}^\ell$ con $\mathbb{E}\|X\|^2 < \infty$, y $m = \mathbb{E}(X)$. Para todo $a \in \mathbb{R}^\ell$:

$$\begin{aligned}
\mathbb{E}\|X - a\|^2 &= \mathbb{E}\|(X - m) + (m - a)\|^2 \\
&= \mathbb{E}\|X - m\|^2 + 2\,\big\langle \underbrace{\mathbb{E}(X - m)}_{=0},\ m - a \big\rangle + \|m - a\|^2 \\
&= \mathbb{E}\|X - m\|^2 + \|m - a\|^2.
\end{aligned}$$

Antes un repaso...

X un vector aleatorio en $\mathbb{R}^\ell$ con $\mathbb{E}\|X\|^2 < \infty$, y $m = \mathbb{E}(X)$. Para todo $a \in \mathbb{R}^\ell$:

$$\begin{aligned}\mathbb{E}\|X-a\|^2 &= \mathbb{E}\|(X-m)+(m-a)\|^2 \\ &= \mathbb{E}\|X-m\|^2 + 2\,\big\langle \underbrace{\mathbb{E}(X-m)}_{=0},\ m-a\big\rangle + \|m-a\|^2 \\ &= \mathbb{E}\|X-m\|^2 + \|m-a\|^2.\end{aligned}$$

Entonces

$$\mathbb{E}(X) = \arg\min_{a\in\mathbb{R}^\ell} \mathbb{E}\|X-a\|^2$$ (y el mínimo es la varianza, $\mathbb{E}\|X-m\|^2$).

La medida empírica

Datos $x_1, \ldots, x_n \in \mathbb{R}^\ell$. La **medida empírica** es

$$\mu_n = \frac{1}{n} \sum_{i=1}^{n} \delta_{x_i} \qquad \text{(peso } 1/n \text{ a cada dato).}$$

La medida empírica

Datos $x_1, \ldots, x_n \in \mathbb{R}^\ell$. La **medida empírica** es

$$\mu_n = \frac{1}{n} \sum_{i=1}^{n} \delta_{x_i} \qquad \text{(peso } 1/n \text{ a cada dato).}$$

$X \sim \mu_n$ es "elegir un dato al azar": $\mathbb{E}_{\mu_n}\big(g(X)\big) = \frac{1}{n}\sum_i g(x_i)$ para toda g.

La medida empírica

Datos $x_1, \ldots, x_n \in \mathbb{R}^\ell$. La **medida empírica** es

$$\mu_n = \frac{1}{n} \sum_{i=1}^{n} \delta_{x_i} \qquad \text{(peso } 1/n \text{ a cada dato).}$$

$X \sim \mu_n$ es "elegir un dato al azar": $\mathbb{E}_{\mu_n}\big(g(X)\big) = \frac{1}{n}\sum_i g(x_i)$ para toda g.

En particular,

$$\mathbb{E}_{\mu_n}(X) = \frac{1}{n} \sum_{i=1}^{n} x_i = \bar{x}_n = \arg\min_{a \in \mathbb{R}^\ell} \frac{1}{n} \sum_{i=1}^{n} \|x_i - a\|^2.$$

La medida empírica

Datos $x_1, \dots, x_n \in \mathbb{R}^\ell$. La **medida empírica** es

$$\mu_n = \frac{1}{n} \sum_{i=1}^{n} \delta_{x_i} \qquad \text{(peso } 1/n \text{ a cada dato).}$$

$X \sim \mu_n$ es "elegir un dato al azar": $\mathbb{E}_{\mu_n}\big(g(X)\big) = \frac{1}{n}\sum_i g(x_i)$ para toda g.

En particular,

$$\mathbb{E}_{\mu_n}(X) = \frac{1}{n} \sum_{i=1}^{n} x_i = \bar{x}_n = \arg\min_{a \in \mathbb{R}^\ell} \frac{1}{n} \sum_{i=1}^{n} \|x_i - a\|^2.$$

Ley de los Grandes Números. Si los x_i son i.i.d. $\sim \mu$, $\bar{x}_n \to \mathbb{E}_\mu(X)$ c.s.

k-medias poblacional y empírico

X un vector aleatorio en $\mathbb{R}^\ell$ con distribución μ.

$$\Phi_1(a, \mu) := \mathbb{E}_{X \sim \mu}(\|X - a\|^2)$$

k-medias poblacional y empírico

X un vector aleatorio en $\mathbb{R}^\ell$ con distribución μ.

$$\Phi_1(a, \mu) := \mathbb{E}_{X\sim\mu}(\|X - a\|^2)$$

La **media** de μ es

$$F_1(\mu) := \arg\min_{a\in\mathbb{R}^\ell} \Phi_1(a, \mu) \qquad (= \mathbb{E}(X)).$$

k-medias poblacional y empírico

X un vector aleatorio en $\mathbb{R}^\ell$ con distribución μ.

$$\Phi_1(a, \mu) := \mathbb{E}_{X\sim\mu}(\|X - a\|^2)$$

La **media** de μ es

$$F_1(\mu) := \arg\min_{a\in\mathbb{R}^\ell} \Phi_1(a, \mu) \qquad (= \mathbb{E}(X)).$$

Más en general,

$$\Phi(A, \mu) := \mathbb{E}_{X\sim\mu}\left(\min_{a\in A} \|X - a\|^2\right), \qquad F_k(\mu) := \arg\min_{A\subseteq\mathbb{R}^\ell, |A|\leq k} \Phi(A, \mu)$$

son las k-**medias** de μ.

k-medias poblacional y empírico

X un vector aleatorio en $\mathbb{R}^\ell$ con distribución μ.

$$\Phi_1(a, \mu) := \mathbb{E}_{X\sim\mu}(\|X - a\|^2)$$

La **media** de μ es

$$F_1(\mu) := \arg\min_{a\in\mathbb{R}^\ell} \Phi_1(a, \mu) \qquad (= \mathbb{E}(X)).$$

Más en general,

$$\Phi(A, \mu) := \mathbb{E}_{X\sim\mu}\left(\min_{a\in A} \|X - a\|^2\right), \qquad F_k(\mu) := \arg\min_{A\subseteq\mathbb{R}^\ell, |A|\leq k} \Phi(A, \mu)$$

son las k-**medias** de μ.

Si $\mu_n = \frac{1}{n}\sum \delta_{x_i}$ (la medida empírica), entonces $F_k(\mu_n) = W_n$.

¿Lo que calculamos se parece a lo que queremos?

Si $x_1, \ldots, x_n$ son i.i.d. con distribución μ y $\mu_n = \frac{1}{n} \sum \delta_{x_i}$

$$F_k(\mu_n) = W_n.$$

¿Lo que calculamos se parece a lo que queremos?

Si $x_1, \ldots, x_n$ son i.i.d. con distribución μ y $\mu_n = \frac{1}{n} \sum \delta_{x_i}$

$$F_k(\mu_n) = W_n.$$

Teorema (Pollard, 1981)

Bajo ciertas hipótesis,

$$F_k(\mu_n) \to F_k(\mu), \qquad \text{casi seguramente.}$$

¿Lo que calculamos se parece a lo que queremos?

Si $x_1, \dots, x_n$ son i.i.d. con distribución μ y $\mu_n = \frac{1}{n} \sum \delta_{x_i}$

$$F_k(\mu_n) = W_n.$$

Teorema (Pollard, 1981)

Bajo ciertas hipótesis,

$$F_k(\mu_n) \to F_k(\mu), \qquad \text{casi seguramente.}$$

Es una **ley de los grandes números** para k-medias.

Para $k = 1$ es exactamente la LGN de Proba.

Versión poblacional vs. versión empírica

	Poblacional (μ)	**Empírica** (μ_n)
Media	$\mathbb{E}(X)$	$\frac{1}{n}\sum_i x_i$
k-medias	$F_k(\mu)$	$F_k(\mu_n) = W_n$

Versión poblacional vs. versión empírica

	Poblacional (μ)	**Empírica** (μ_n)
Media	$\mathbb{E}(X)$	$\frac{1}{n}\sum_i x_i$
k-medias	$F_k(\mu)$	$F_k(\mu_n) = W_n$

Plug-in: definir primero el objeto poblacional y después reemplazar μ por μ_n.

(a) nos da un **método automático para proponer estimadores**;

Versión poblacional vs. versión empírica

	Poblacional (μ)	**Empírica** (μ_n)
Media	$\mathbb{E}(X)$	$\frac{1}{n}\sum_i x_i$
k-medias	$F_k(\mu)$	$F_k(\mu_n) = W_n$

Plug-in: definir primero el objeto poblacional y después reemplazar μ por μ_n.

(a) nos da un **método automático para proponer estimadores**;

(b) **entendemos qué estamos estimando** (¡hay algo que estimar!);

Versión poblacional vs. versión empírica

	Poblacional (μ)	**Empírica** (μ_n)
Media	$\mathbb{E}(X)$	$\frac{1}{n}\sum_i x_i$
k-medias	$F_k(\mu)$	$F_k(\mu_n) = W_n$

Plug-in: definir primero el objeto poblacional y después reemplazar μ por μ_n.

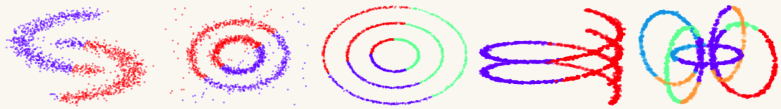
(a) nos da un **método automático para proponer estimadores**;

(b) **entendemos qué estamos estimando** (¡hay algo que estimar!);

(c) con suerte, podemos **demostrar que el estimador es consistente**.

k-medias

- k-medias usa explícitamente la distancia euclídea.

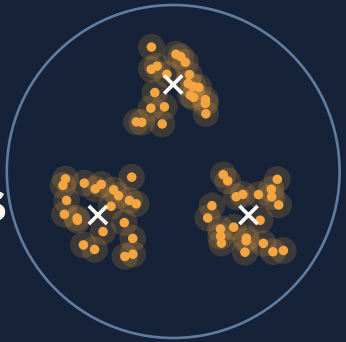


©U. Shaham, K. Stanton, H. Li, R. Basri, B. Nadler, Y. Kluger, (2018).

¿Y si la distancia euclídea no es la adecuada?

3

La geometría de los datos



Hipótesis de la variedad

Los datos viven en $\mathbb{R}^D$, pero en realidad están cerca de una **superficie** $\mathcal{M}$ de dimensión d, con $d \ll D$.

Hipótesis de la variedad

Los datos viven en $\mathbb{R}^D$, pero en realidad están cerca de una **superficie** $\mathcal{M}$ de dimensión d, con $d \ll D$.

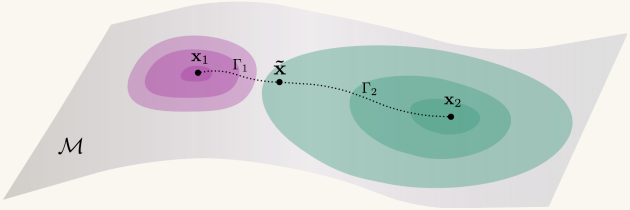
Tenemos n puntos en $\mathcal{M}$ con densidad $f : \mathcal{M} \to \mathbb{R}_{\geq 0}$.



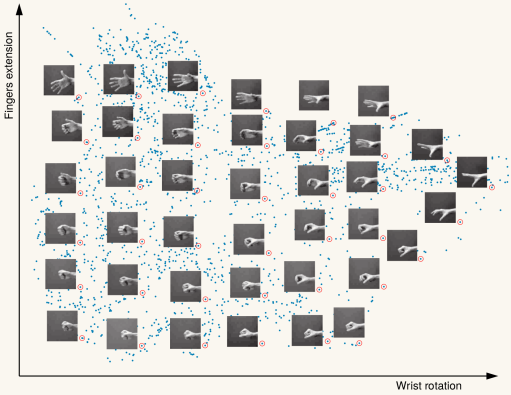
Hipótesis de la variedad

Los datos viven en $\mathbb{R}^D$, pero en realidad están cerca de una **superficie** $\mathcal{M}$ de dimensión d, con $d \ll D$.

Tenemos n puntos en $\mathcal{M}$ con densidad $f : \mathcal{M} \to \mathbb{R}_{\geq 0}$.



Motivación: imágenes de manos



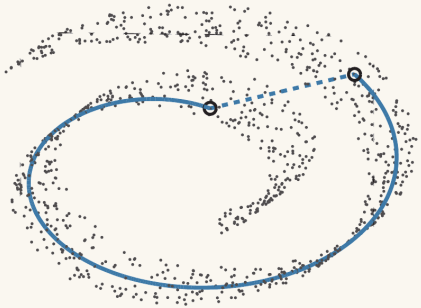
©J. B. Tenenbaum, V. de Silva, J. C. Langford, Science (2000)

Motivación: MNIST



©MNIST Dataset

Hipótesis de la variedad



©J. B. Tenenbaum, V. de Silva, J. C. Langford, Science (2000)

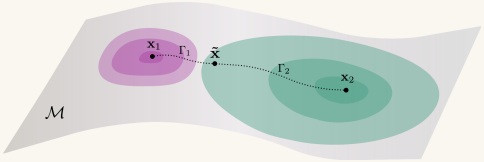
La distancia “en línea recta” no respeta la forma de los datos.

Distancia de Fermat (poblacional)

$f : \mathcal{M} \to \mathbb{R}$ una densidad.

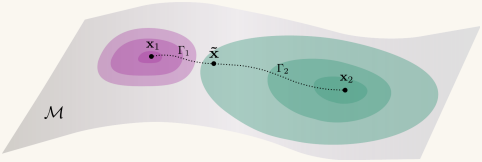
Distancia de Fermat (poblacional)

$f : \mathcal{M} \to \mathbb{R}$ una densidad.



Distancia de Fermat (poblacional)

$f : \mathcal{M} \to \mathbb{R}$ una densidad.

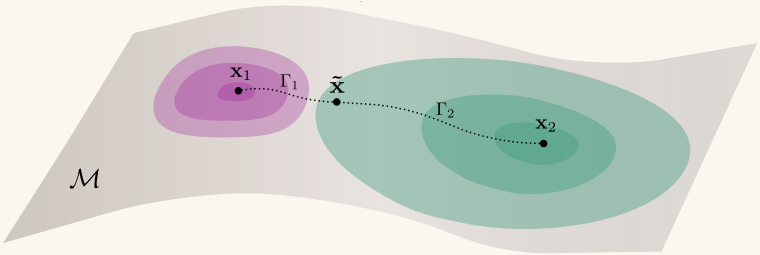


Para $x, y \in \mathcal{M}$ y $p > 1$ definimos la **distancia de Fermat**

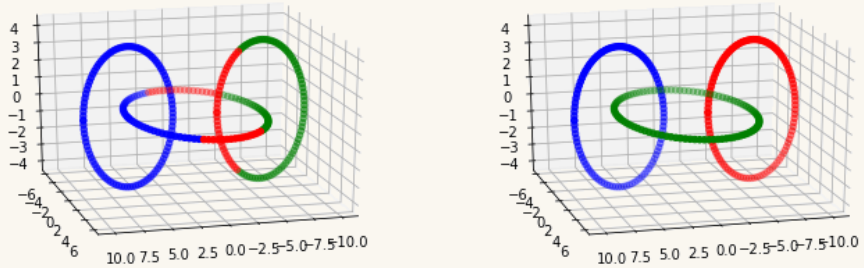
$$\mathcal{D}^p(x, y) = \inf_{\gamma} \int_{\gamma} \frac{1}{f^{(p-1)/d}} \, ds,$$

donde el ínfimo es sobre todas las curvas γ de x a y.

Una buena distancia para hacer clustering...



Clustering

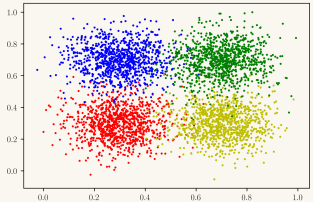


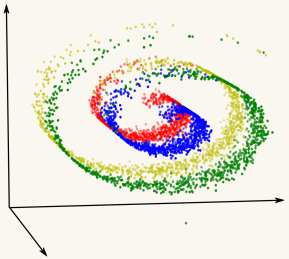
k-medias con distancia euclídea vs. distancia de Fermat.

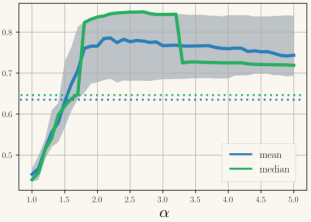
© N. Chehebar

Clustering con Fermat

k-medias en el Swiss roll







©Facundo Sapienza

Pero... no conocemos f ni $\mathcal{M}$

Solo tenemos los datos.

Pero... no conocemos f ni $\mathcal{M}$

Solo tenemos los datos.

Hay que aprender la distancia a partir de los datos.

Distancia de Fermat muestral

- $\mathbb{X}$ un conjunto finito de puntos en $\mathbb{R}^D$, $p \geq 1$. Para $x, y \in \mathbb{X}$,

$r_{xy} = (x_1, \ldots, x_m)$ un camino de x a y que salta *de dato en dato*.

$$\mathcal{T}(r_{xy}) = \sum_{j=1}^{m-1} \|x_{j+1} - x_j\|^p, \qquad D_{\mathbb{X}}^p(x, y) = \min_{r_{xy}} \mathcal{T}(r_{xy})$$

Si $p > 1$, los saltos largos se penalizan.

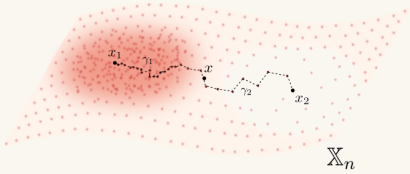
Distancia de Fermat muestral

- $\mathbb{X}$ un conjunto finito de puntos en $\mathbb{R}^D$, $p \geq 1$. Para $x, y \in \mathbb{X}$,

$r_{xy} = (x_1, \ldots, x_m)$ un camino de x a y que salta *de dato en dato*.

$$\mathcal{T}(r_{xy}) = \sum_{j=1}^{m-1} \|x_{j+1} - x_j\|^p, \qquad D_{\mathbb{X}}^p(x, y) = \min_{r_{xy}} \mathcal{T}(r_{xy})$$

Si $p > 1$, los saltos largos se penalizan.

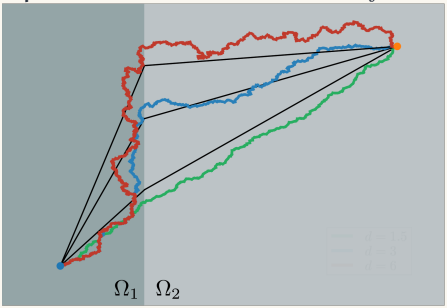


Distancia de Fermat muestral para puntos i.i.d.

- Sea $\mathbb{X}$ un conjunto de n puntos i.i.d. con densidad f.

Distancia de Fermat muestral para puntos i.i.d.

- Sea $\mathbb{X}$ un conjunto de n puntos i.i.d. con densidad f.

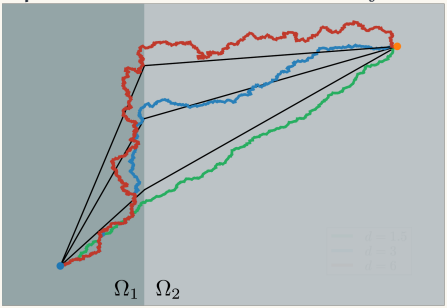


El camino óptimo para $p = 1.5$, $p = 3$ y $p = 6$.

La densidad de puntos en Ω_1 es mayor que en Ω_2. Click.

Distancia de Fermat muestral para puntos i.i.d.

- Sea $\mathbb{X}$ un conjunto de n puntos i.i.d. con densidad f.



El camino óptimo para $p = 1.5$, $p = 3$ y $p = 6$.

La densidad de puntos en Ω_1 es mayor que en Ω_2. Click.

Es un problema de caminos mínimos en un grafo (Dijkstra).

Links: distancias de Fermat



Consistencia

$\mathbb{X}_n = \{x_1, \ldots, x_n\}$ i.i.d. $\sim f > 0$ (continua) en una superficie compacta $\mathcal{M}$.

Consistencia

$\mathbb{X}_n = \{x_1, \ldots, x_n\}$ i.i.d. $\sim f > 0$ (continua) en una superficie compacta $\mathcal{M}$.

Teorema (G., Jonckheere, Sapienza 2018)

Para $p > 1$, $x, y \in \mathcal{M}$ y $\varepsilon > 0$ existen $\theta, \kappa > 0$ tales que

$$\mathbb{P}\left(|c_n D^p_{\mathbb{X}_n}(x, y) - \mu \mathcal{D}^p(x, y)| > \varepsilon\right) \leq e^{-\theta n^\kappa}$$

para n suficientemente grande ($c_n = n^{(p-1)/d}$).

Consistencia

$\mathbb{X}_n = \{x_1, \ldots, x_n\}$ i.i.d. $\sim f > 0$ (continua) en una superficie compacta $\mathcal{M}$.

Teorema (G., Jonckheere, Sapienza 2018)

Para $p > 1$, $x, y \in \mathcal{M}$ y $\varepsilon > 0$ existen $\theta, \kappa > 0$ tales que

$$\mathbb{P}\left(|c_n D^p_{\mathbb{X}_n}(x, y) - \mu \mathcal{D}^p(x, y)| > \varepsilon\right) \leq e^{-\theta n^\kappa}$$

para n suficientemente grande ($c_n = n^{(p-1)/d}$).

¡Bien!

Consistencia

$\mathbb{X}_n = \{x_1, \ldots, x_n\}$ i.i.d. $\sim f > 0$ (continua) en una superficie compacta $\mathcal{M}$.

Teorema (G., Jonckheere, Sapienza 2018)

Para $p > 1$, $x, y \in \mathcal{M}$ y $\varepsilon > 0$ existen $\theta, \kappa > 0$ tales que

$$\mathbb{P}\left(|c_n D^p_{\mathbb{X}_n}(x, y) - \mu \mathcal{D}^p(x, y)| > \varepsilon\right) \leq e^{-\theta n^\kappa}$$

para n suficientemente grande ($c_n = n^{(p-1)/d}$).

¡Bien!

Pero no alcanza para algunas aplicaciones
(aprender topología, k-medias, ...).

Consistencia

$\mathbb{X}_n = \{x_1, \ldots, x_n\}$ i.i.d. $\sim f > 0$ (continua) en una superficie compacta $\mathcal{M}$.

Teorema (G., Jonckheere, Sapienza 2018)

Para $p > 1$, $x, y \in \mathcal{M}$ y $\varepsilon > 0$ existen $\theta, \kappa > 0$ tales que

$$\mathbb{P}\left(|c_n D^p_{\mathbb{X}_n}(x, y) - \mu \mathcal{D}^p(x, y)| > \varepsilon\right) \leq e^{-\theta n^\kappa}$$

para n suficientemente grande ($c_n = n^{(p-1)/d}$).

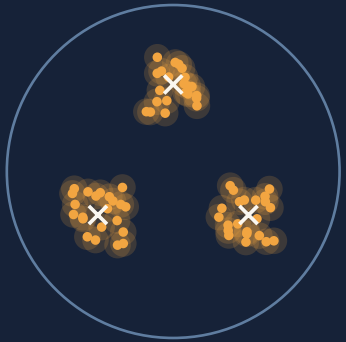
¡Bien!

Pero no alcanza para algunas aplicaciones
(aprender topología, k-medias, ...).

Converge *cada* distancia. Necesitamos que converja *todo el espacio a la vez*.

4

Espacios métricos



Espacios métricos

$\mathbb{X}$ un conjunto. Una *distancia* es una función

$$d\colon \mathbb{X} \times \mathbb{X} \to \mathbb{R}_{\geq 0}, \qquad \text{tal que}$$

- $d(x, y) = 0 \iff x = y$

Espacios métricos

$\mathbb{X}$ un conjunto. Una *distancia* es una función

$$d\colon \mathbb{X} \times \mathbb{X} \to \mathbb{R}_{\geq 0}, \qquad \text{tal que}$$

- $d(x, y) = 0 \iff x = y$
- $d(x, y) = d(y, x)$, para todo $x, y \in \mathbb{X}$

Espacios métricos

$\mathbb{X}$ un conjunto. Una *distancia* es una función

$$d\colon \mathbb{X} \times \mathbb{X} \to \mathbb{R}_{\geq 0}, \qquad \text{tal que}$$

- $d(x,y) = 0 \iff x = y$
- $d(x,y) = d(y,x), \quad$ para todo $x, y \in \mathbb{X}$
- $d(x,z) \leq d(x,y) + d(y,z) \quad$ para todo $x, y, z \in \mathbb{X}$ (desigualdad triangular)

Espacios métricos

$\mathbb{X}$ un conjunto. Una *distancia* es una función

$$d\colon \mathbb{X} \times \mathbb{X} \to \mathbb{R}_{\geq 0}, \qquad \text{tal que}$$

- $d(x,y) = 0 \iff x = y$
- $d(x,y) = d(y,x), \quad$ para todo $x, y \in \mathbb{X}$
- $d(x,z) \leq d(x,y) + d(y,z) \quad$ para todo $x, y, z \in \mathbb{X}$ (desigualdad triangular)

Espacios métricos

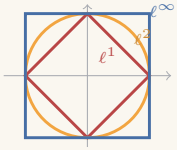
$\mathbb{X}$ un conjunto. Una *distancia* es una función

$$d\colon \mathbb{X} \times \mathbb{X} \to \mathbb{R}_{\geq 0}, \qquad \text{tal que}$$

- $d(x,y) = 0 \iff x = y$
- $d(x,y) = d(y,x), \quad$ para todo $x, y \in \mathbb{X}$
- $d(x,z) \leq d(x,y) + d(y,z) \quad$ para todo $x, y, z \in \mathbb{X}$ (desigualdad triangular)

Decimos que $(\mathbb{X}, d)$ es un *espacio métrico*.

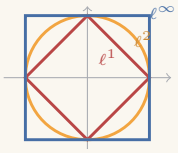
Ejemplos de espacios métricos



Normas en $\mathbb{R}^\ell$

las bolas de radio 1 de ℓ^1, ℓ^2, ℓ^∞

Ejemplos de espacios métricos



Normas en $\mathbb{R}^\ell$

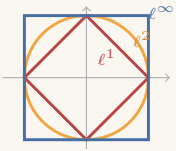
las bolas de radio 1 de ℓ^1, ℓ^2, ℓ^∞



La esfera

geodésica: por la superficie

Ejemplos de espacios métricos



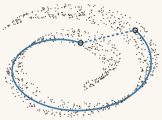
Normas en $\mathbb{R}^\ell$

las bolas de radio 1 de ℓ^1, ℓ^2, ℓ^∞



La esfera

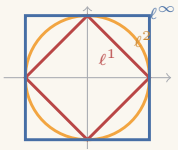
geodésica: por la superficie



Variedades $(\mathcal{M}, d)$

geodésica, Fermat, difusión, …

Ejemplos de espacios métricos



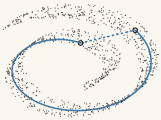
Normas en $\mathbb{R}^\ell$

las bolas de radio 1 de ℓ^1, ℓ^2, ℓ^∞



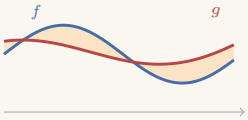
La esfera

geodésica: por la superficie



Variedades $(\mathcal{M}, d)$

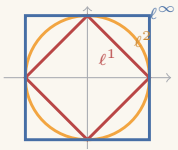
geodésica, Fermat, difusión, …



Funciones

$\sup|f-g|$, $\left(\int|f-g|^2\right)^{1/2}$, …

Ejemplos de espacios métricos



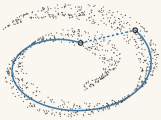
Normas en $\mathbb{R}^\ell$

las bolas de radio 1 de ℓ^1, ℓ^2, ℓ^∞



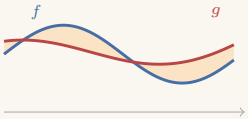
La esfera

geodésica: por la superficie



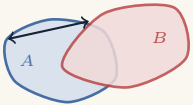
Variedades $(\mathcal{M}, d)$

geodésica, Fermat, difusión, …



Funciones

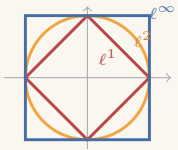
$\sup|f-g|$, $\left(\int|f-g|^2\right)^{1/2}$, …



Conjuntos

distancia de Hausdorff

Ejemplos de espacios métricos



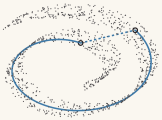
Normas en $\mathbb{R}^\ell$

las bolas de radio 1 de ℓ^1, ℓ^2, ℓ^∞



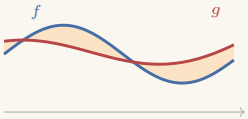
La esfera

geodésica: por la superficie



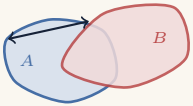
Variedades $(\mathcal{M}, d)$

geodésica, Fermat, difusión, …



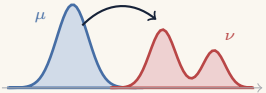
Funciones

$\sup|f-g|$, $\left(\int|f-g|^2\right)^{1/2}$, …



Conjuntos

distancia de Hausdorff



Distribuciones

Wasserstein: “mover la arena”

Repaso: k-medias en el espacio euclídeo

$$\Phi_1(a, \mu) := \int_{\mathbb{R}^\ell} \|x - a\|^2 \, d\mu(x) = \mathbb{E}_{X \sim \mu}(\|X - a\|^2)$$

La media de μ es la única solución de

$$F_1(\mu) = \arg\min_{a \in \mathbb{R}^\ell} \Phi_1(a, \mu).$$

Más en general,

$$\Phi(A, \mu) := \int_{\mathbb{R}^\ell} \min_{a \in A} \|x - a\|^2 \, d\mu(x).$$

Las k-medias de μ son

$$F_k(\mu) := \arg\min_{A \subseteq \mathbb{R}^\ell, |A| \leq k} \Phi(A, \mu)$$

k-medias en espacios métricos con medida

$(\mathbb{X}, d, \mu)$ un espacio métrico con una medida de probabilidad μ.

Def.

$$\Phi_1(a, \mu) := \int_{\mathbb{X}} d^2(x, a)\, d\mu(x) = \mathbb{E}_{X\sim\mu}(d^2(X, a))$$

El **baricentro** (o media de Fréchet) de μ es

$$F_1(\mu) := \arg\min_{a\in\mathbb{X}} \Phi_1(a, \mu).$$

Más en general,

$$\Phi(A, \mu) := \int_{\mathbb{X}} \min_{a\in A} d^2(x, a)\, d\mu(x).$$

Los k**-baricentros** de μ son

$$F_k(\mu) := \arg\min_{A\subseteq\mathbb{X}, |A|\leq k} \Phi(A, \mu)$$

Ejemplos ($k = 1$)

1. En $\mathbb{X} = \mathbb{R}^\ell$ con la distancia euclídea

$$F_1(\mu) = \mathbb{E}_\mu(X), \qquad F_1\left(\frac{1}{n}\sum_{i=1}^{n}\delta_{x_i}\right) = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Ejemplos ($k = 1$)

1. En $\mathbb{X} = \mathbb{R}^\ell$ con la distancia euclídea

$$F_1(\mu) = \mathbb{E}_\mu(X), \qquad F_1\left(\frac{1}{n}\sum_{i=1}^n \delta_{x_i}\right) = \frac{1}{n}\sum_{i=1}^n x_i.$$

2. En $\mathbb{X} = \mathbb{S}^1 = \{x \in \mathbb{R}^2 \colon \|x\| = 1\}$ con la distancia geodésica:

a. $\mu = \mathrm{Unif}(\mathbb{S}^1)$, $F_1(\mu) = \mathbb{S}^1$.

Ejemplos ($k = 1$)

1. En $\mathbb{X} = \mathbb{R}^\ell$ con la distancia euclídea

$$F_1(\mu) = \mathbb{E}_\mu(X), \qquad F_1\left(\frac{1}{n}\sum_{i=1}^n \delta_{x_i}\right) = \frac{1}{n}\sum_{i=1}^n x_i.$$

2. En $\mathbb{X} = \mathbb{S}^1 = \{x \in \mathbb{R}^2 \colon \|x\| = 1\}$ con la distancia geodésica:

a. $\mu = \mathrm{Unif}(\mathbb{S}^1)$, $F_1(\mu) = \mathbb{S}^1$. (¡todos los puntos son baricentro!)

b. $\mu = \mathrm{Unif}(\mathbb{S}^1 \backslash \{\mathsf{N}\})$,

Ejemplos ($k = 1$)

1. En $\mathbb{X} = \mathbb{R}^\ell$ con la distancia euclídea

$$F_1(\mu) = \mathbb{E}_\mu(X), \qquad F_1\left(\frac{1}{n}\sum_{i=1}^n \delta_{x_i}\right) = \frac{1}{n}\sum_{i=1}^n x_i.$$

2. En $\mathbb{X} = \mathbb{S}^1 = \{x \in \mathbb{R}^2 \colon \|x\| = 1\}$ con la distancia geodésica:

a. $\mu = \mathrm{Unif}(\mathbb{S}^1)$, $F_1(\mu) = \mathbb{S}^1$. (¡todos los puntos son baricentro!)

b. $\mu = \mathrm{Unif}(\mathbb{S}^1 \backslash \{\mathsf{N}\})$, $F_1(\mu) = \mathbb{S}^1$.

Ejemplos ($k = 1$)

1. En $\mathbb{X} = \mathbb{R}^\ell$ con la distancia euclídea

$$F_1(\mu) = \mathbb{E}_\mu(X), \qquad F_1\left(\frac{1}{n}\sum_{i=1}^n \delta_{x_i}\right) = \frac{1}{n}\sum_{i=1}^n x_i.$$

2. En $\mathbb{X} = \mathbb{S}^1 = \{x \in \mathbb{R}^2 \colon \|x\| = 1\}$ con la distancia geodésica:
a. $\mu = \mathrm{Unif}(\mathbb{S}^1)$, $F_1(\mu) = \mathbb{S}^1$. (¡todos los puntos son baricentro!)
b. $\mu = \mathrm{Unif}(\mathbb{S}^1 \backslash \{\mathsf{N}\})$, $F_1(\mu) = \mathbb{S}^1$.

3. En $\mathbb{X} = \mathbb{S}^1 \backslash \{\mathsf{N}\}$, $\mu = \mathrm{Unif}(\mathbb{S}^1 \backslash \{\mathsf{N}\})$,

Ejemplos ($k = 1$)

1. En $\mathbb{X} = \mathbb{R}^\ell$ con la distancia euclídea

$$F_1(\mu) = \mathbb{E}_\mu(X), \qquad F_1\left(\frac{1}{n}\sum_{i=1}^n \delta_{x_i}\right) = \frac{1}{n}\sum_{i=1}^n x_i.$$

2. En $\mathbb{X} = \mathbb{S}^1 = \{x \in \mathbb{R}^2 \colon \|x\| = 1\}$ con la distancia geodésica:
a. $\mu = \mathrm{Unif}(\mathbb{S}^1)$, $F_1(\mu) = \mathbb{S}^1$. (¡todos los puntos son baricentro!)
b. $\mu = \mathrm{Unif}(\mathbb{S}^1 \backslash \{\mathsf{N}\})$, $F_1(\mu) = \mathbb{S}^1$.

3. En $\mathbb{X} = \mathbb{S}^1 \backslash \{\mathsf{N}\}$, $\mu = \mathrm{Unif}(\mathbb{S}^1 \backslash \{\mathsf{N}\})$, $F_1(\mu) = \{\mathsf{S}\}$.

Ejemplos ($k = 1$)

1. En $\mathbb{X} = \mathbb{R}^\ell$ con la distancia euclídea

$$F_1(\mu) = \mathbb{E}_\mu(X), \qquad F_1\left(\frac{1}{n}\sum_{i=1}^n \delta_{x_i}\right) = \frac{1}{n}\sum_{i=1}^n x_i.$$

2. En $\mathbb{X} = \mathbb{S}^1 = \{x \in \mathbb{R}^2 \colon \|x\| = 1\}$ con la distancia geodésica:
a. $\mu = \mathrm{Unif}(\mathbb{S}^1)$, $F_1(\mu) = \mathbb{S}^1$. (¡todos los puntos son baricentro!)
b. $\mu = \mathrm{Unif}(\mathbb{S}^1 \backslash \{\mathsf{N}\})$, $F_1(\mu) = \mathbb{S}^1$.

3. En $\mathbb{X} = \mathbb{S}^1 \backslash \{\mathsf{N}\}$, $\mu = \mathrm{Unif}(\mathbb{S}^1 \backslash \{\mathsf{N}\})$, $F_1(\mu) = \{\mathsf{S}\}$.

4. $\mathbb{X} = [-1, 0) \cup (0, 1] \subset \mathbb{R}$ con la distancia heredada, $\mu = \mathrm{Unif}$,

Ejemplos ($k = 1$)

1. En $\mathbb{X} = \mathbb{R}^\ell$ con la distancia euclídea

$$F_1(\mu) = \mathbb{E}_\mu(X), \qquad F_1\left(\frac{1}{n}\sum_{i=1}^n \delta_{x_i}\right) = \frac{1}{n}\sum_{i=1}^n x_i.$$

2. En $\mathbb{X} = \mathbb{S}^1 = \{x \in \mathbb{R}^2 \colon \|x\| = 1\}$ con la distancia geodésica:
a. $\mu = \mathrm{Unif}(\mathbb{S}^1)$, $F_1(\mu) = \mathbb{S}^1$. (¡todos los puntos son baricentro!)
b. $\mu = \mathrm{Unif}(\mathbb{S}^1 \backslash \{\mathsf{N}\})$, $F_1(\mu) = \mathbb{S}^1$.

3. En $\mathbb{X} = \mathbb{S}^1 \backslash \{\mathsf{N}\}$, $\mu = \mathrm{Unif}(\mathbb{S}^1 \backslash \{\mathsf{N}\})$, $F_1(\mu) = \{\mathsf{S}\}$.

4. $\mathbb{X} = [-1, 0) \cup (0, 1] \subset \mathbb{R}$ con la distancia heredada, $\mu = \mathrm{Unif}$, $F_1(\mu) = \varnothing$.
(el baricentro "debería" ser el 0, pero no está en el espacio)

Ejemplos ($k \geq 1$)

Los k-baricentros de μ son

$$F_k(\mu) := \arg\min_{A \subseteq \mathbb{X}, |A| \leq k} \Phi(A, \mu)$$

Si $\mu = \mu_n$ (medida empírica)

$$F_k(\mu_n) = \arg\min_{A \subseteq \mathbb{X}, |A| \leq k} \sum_{i=1}^{n} \min_{a \in A} d^2(x_i, a)$$

(k-medias empírico es k-medias poblacional con μ = medida empírica)

5

¿Y si no conocemos d?



Distancias de difusión

• Grafo de vecinos sobre los datos y un **paseo al azar**: $p_t(x, \cdot)$ = distribución del paseo a tiempo t si arrancó en x.

Distancias de difusión

- Grafo de vecinos sobre los datos y un **paseo al azar**: $p_t(x, \cdot)$ = distribución del paseo a tiempo t si arrancó en x.
- La **distancia de difusión** compara esas distribuciones:

$$D_t(x, y) = \left\| p_t(x, \cdot) - p_t(y, \cdot) \right\|_{L^2}.$$

Distancias de difusión

• Grafo de vecinos sobre los datos y un **paseo al azar**: $p_t(x, \cdot)$ = distribución del paseo a tiempo t si arrancó en x.

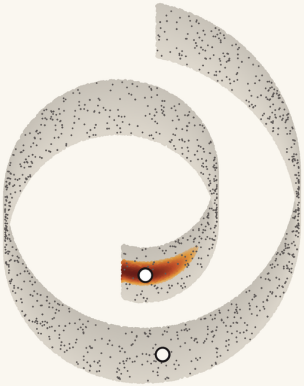
• La **distancia de difusión** compara esas distribuciones:

$$D_t(x, y) = \left\| p_t(x, \cdot) - p_t(y, \cdot) \right\|_{L^2}.$$

• Dos puntos están cerca si las distribuciones de los paseos que arrancan de cada uno se parecen.

Distancias de difusión en el Swiss roll

arranca en la punta



$t = 0$

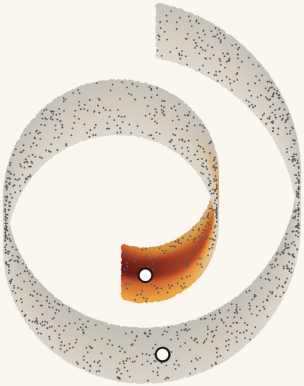
arranca en el brazo de afuera



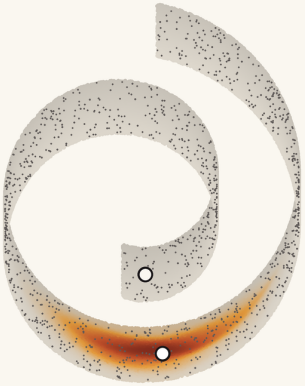
$D_t(x, y) = 55.25$

Distancias de difusión en el Swiss roll

arranca en la punta



arranca en el brazo de afuera



$t = 20$ $D_t(x, y) = 7.15$

Distancias de difusión en el Swiss roll

arranca en la punta



arranca en el brazo de afuera



$t = 100$ $D_t(x, y) = 3.21$

Distancias de difusión en el Swiss roll

arranca en la punta



$t = 400$

arranca en el brazo de afuera



$D_t(x, y) = 2.29$

Distancias de difusión en el Swiss roll

arranca en la punta



$t = 1500$

arranca en el brazo de afuera



$D_t(x, y) = 1.26$

Distancias de difusión en el Swiss roll

arranca en la punta



arranca en el brazo de afuera



$t = 5000$ $D_t(x, y) = 0.40$

Distancias de difusión en el Swiss roll

arranca en la punta



$t = 20000$

arranca en el brazo de afuera



$D_t(x, y) = 0.00$

Spectral clustering

- ¿Quién usó alguna vez spectral clustering?

Spectral clustering

- ¿Quién usó alguna vez spectral clustering?
- ¿Quién puede explicar en qué consiste spectral clustering?

Spectral clustering

- ¿Quién usó alguna vez spectral clustering?
- ¿Quién puede explicar en qué consiste spectral clustering?

Spectral clustering $\approx$ k-medias con la distancia de difusión
(salvo los pesos).

¡No culpes a k-medias!

Distancias aprendidas

$\mathbb{X} = (\mathcal{M}, d, \mu)$ una superficie (compacta) con una medida μ de densidad f.

$\mathbb{X}_n = \{x_1, \ldots, x_n\}$ i.i.d. $\sim f$, $\mu_n = \mathrm{Unif}(\mathbb{X}_n)$ la medida empírica.

Distancias aprendidas

$\mathbb{X} = (\mathcal{M}, d, \mu)$ una superficie (compacta) con una medida μ de densidad f.

$\mathbb{X}_n = \{x_1, \ldots, x_n\}$ i.i.d. $\sim f$, $\mu_n = \mathrm{Unif}(\mathbb{X}_n)$ la medida empírica.

(a) $d_n = c_n D^p_{\mathbb{X}_n}$ o (b) $d_n = \mathrm{Isomap}$ o (c) $d_n =$ distancia de difusión

$(\mathbb{X}_n, d_n, \mu_n)$ es un espacio métrico con medida *aleatorio*.

Distancias aprendidas

$\mathbb{X} = (\mathcal{M}, d, \mu)$ una superficie (compacta) con una medida μ de densidad f.

$\mathbb{X}_n = \{x_1, \ldots, x_n\}$ i.i.d. $\sim f$, $\mu_n = \mathrm{Unif}(\mathbb{X}_n)$ la medida empírica.

(a) $d_n = c_n D^p_{\mathbb{X}_n}$ o (b) $d_n = \mathrm{Isomap}$ o (c) $d_n =$ distancia de difusión

$(\mathbb{X}_n, d_n, \mu_n)$ es un espacio métrico con medida *aleatorio*.

¿Los k-baricentros de $(\mathbb{X}_n, d_n, \mu_n)$ convergen a los de $(\mathbb{X}, d, \mu)$?

Ejemplo: espacio de Wasserstein

(E, d) un espacio métrico compacto, $\mathcal{W} = \mathcal{W}(E) =$ medidas de probabilidad en E.

Para $\mu, \nu \in \mathcal{W}$

$$d_W(\mu, \nu) = \left(\inf_{\pi \in \Gamma(\mu,\nu)} \int d^2(x, y)\, d\pi(x, y) \right)^{1/2}$$

(el costo mínimo de "mover la arena" de μ a ν).

$(\mathcal{W}(E), d_W)$ es un espacio métrico.

Ejemplo: espacio de Wasserstein

(E, d) un espacio métrico compacto, $\mathcal{W} = \mathcal{W}(E) =$ medidas de probabilidad en E.

Para $\mu, \nu \in \mathcal{W}$

$$d_W(\mu, \nu) = \left(\inf_{\pi \in \Gamma(\mu,\nu)} \int d^2(x, y)\, d\pi(x, y) \right)^{1/2}$$

(el costo mínimo de "mover la arena" de μ a ν).

$(\mathcal{W}(E), d_W)$ es un espacio métrico.

Le ponemos una medida: (X, Z) un vector aleatorio, $\mu_z := \mathcal{L}(X|Z = z)$, $\mathbb{P}(\mu_z) = p_Z(z)$.

Ejemplo: espacio de Wasserstein

(E, d) un espacio métrico compacto, $\mathcal{W} = \mathcal{W}(E) =$ medidas de probabilidad en E.

Para $\mu, \nu \in \mathcal{W}$

$$d_W(\mu, \nu) = \left(\inf_{\pi \in \Gamma(\mu,\nu)} \int d^2(x, y)\, d\pi(x, y) \right)^{1/2}$$

(el costo mínimo de "mover la arena" de μ a ν).

$(\mathcal{W}(E), d_W)$ es un espacio métrico.

Le ponemos una medida: (X, Z) un vector aleatorio, $\mu_z := \mathcal{L}(X|Z = z)$, $\mathbb{P}(\mu_z) = p_Z(z)$.

El baricentro de $(\mathcal{W}(E), d_W, \mathbb{P})$ se llama **baricentro de Wasserstein** (y análogamente, k-baricentros de Wasserstein).

k-baricentros de Wasserstein empíricos

$(X_1, Z_1), \dots (X_n, Z_n)$ una muestra i.i.d., $\mu_z^n = \frac{1}{n_z} \sum_{i=1}^n \delta_{X_i} \mathbf{1}\{Z_i = z\}$

$$\mathbb{X}_n = \{\mu_z^n\}, \qquad \mathbb{P}_n(\mu_z^n) = \frac{\#\{i \colon Z_i = z\}}{n}$$

k-baricentros de Wasserstein empíricos

$(X_1, Z_1), \dots (X_n, Z_n)$ una muestra i.i.d., $\mu_z^n = \frac{1}{n_z} \sum_{i=1}^n \delta_{X_i} \mathbf{1}\{Z_i = z\}$

$$\mathbb{X}_n = \{\mu_z^n\}, \qquad \mathbb{P}_n(\mu_z^n) = \frac{\#\{i \colon Z_i = z\}}{n}$$

- $\mathbb{P}_n$ no es la medida empírica de una muestra i.i.d. de $\mathbb{P}$, pero $\mathbb{P}_n \Rightarrow \mathbb{P}$.

k-baricentros de Wasserstein empíricos

$(X_1, Z_1), \dots (X_n, Z_n)$ una muestra i.i.d., $\mu_z^n = \frac{1}{n_z} \sum_{i=1}^n \delta_{X_i} \mathbf{1}\{Z_i = z\}$

$$\mathbb{X}_n = \{\mu_z^n\}, \qquad \mathbb{P}_n(\mu_z^n) = \frac{\#\{i \colon Z_i = z\}}{n}$$

- $\mathbb{P}_n$ no es la medida empírica de una muestra i.i.d. de $\mathbb{P}$, pero $\mathbb{P}_n \Rightarrow \mathbb{P}$.
- Tomamos $d_n(\mu_z, \mu_{z'}) = d_W(\mu_z^n, \mu_{z'}^n)$.

k-baricentros de Wasserstein empíricos

$(X_1, Z_1), \dots (X_n, Z_n)$ una muestra i.i.d., $\mu_z^n = \frac{1}{n_z} \sum_{i=1}^n \delta_{X_i} \mathbf{1}\{Z_i = z\}$

$$\mathbb{X}_n = \{\mu_z^n\}, \qquad \mathbb{P}_n(\mu_z^n) = \frac{\#\{i \colon Z_i = z\}}{n}$$

- $\mathbb{P}_n$ no es la medida empírica de una muestra i.i.d. de $\mathbb{P}$, pero $\mathbb{P}_n \Rightarrow \mathbb{P}$.
- Tomamos $d_n(\mu_z, \mu_{z'}) = d_W(\mu_z^n, \mu_{z'}^n)$.
- **La distancia también se estima a partir de los datos**.

6

¿Cuándo convergen los k-baricentros?



¿Qué quiere decir que dos espacios métricos estén cerca?

Distancia de Gromov-Hausdorff

$$d_{GH}\big((\mathbb{X}, d_{\mathbb{X}}), (\mathbb{Y}, d_{\mathbb{Y}})\big) := \inf\{d_H(h_1(\mathbb{X}), h_2(\mathbb{Y}))\},$$

- el ínfimo es sobre todas las formas de meter isométricamente $h_1 \colon \mathbb{X} \to \mathbb{W}$, $h_2 \colon \mathbb{Y} \to \mathbb{W}$ en un espacio métrico común.
- d_H es la distancia de Hausdorff.

¿Qué quiere decir que dos espacios métricos estén cerca?

Distancia de Gromov-Hausdorff

$$d_{GH}\big((\mathbb{X}, d_{\mathbb{X}}), (\mathbb{Y}, d_{\mathbb{Y}})\big) := \inf\{d_H(h_1(\mathbb{X}), h_2(\mathbb{Y}))\},$$

- el ínfimo es sobre todas las formas de meter isométricamente $h_1 \colon \mathbb{X} \to \mathbb{W}$, $h_2 \colon \mathbb{Y} \to \mathbb{W}$ en un espacio métrico común.
- d_H es la distancia de Hausdorff.

Idea: los "acomodo" lo mejor posible uno encima del otro y miro cuánto difieren.

Consistencia (de todo el espacio)

- **Espacio poblacional:** $(\mathcal{M}, \mathcal{D}^p)$;
- **Espacio muestral:** $\left(\mathbb{X}_n, c_n D^p_{\mathbb{X}_n}\right)$.

Consistencia (de todo el espacio)

- **Espacio poblacional:** $(\mathcal{M}, \mathcal{D}^p)$;
- **Espacio muestral:** $\left(\mathbb{X}_n, c_n D^p_{\mathbb{X}_n}\right)$.

Teorema (Fernández, Borghini, Mindlin, G. 2023)

Para $\varepsilon > 0$ existen $\theta, \kappa > 0$ tales que

$$\mathbb{P}\left(d_{GH}\left(\left(\mathcal{M}, \mu\mathcal{D}^p\right), \left(\mathbb{X}_n, c_n D^p_{\mathbb{X}_n}\right)\right) > \varepsilon\right) \leq e^{-\theta n^\kappa}$$

para n suficientemente grande.

Consistencia (de todo el espacio)

- **Espacio poblacional:** $(\mathcal{M}, \mathcal{D}^p)$;
- **Espacio muestral:** $\left(\mathbb{X}_n, c_n D^p_{\mathbb{X}_n}\right)$.

Teorema (Fernández, Borghini, Mindlin, G. 2023)

Para $\varepsilon > 0$ existen $\theta, \kappa > 0$ tales que

$$\mathbb{P}\left(d_{GH}\left(\left(\mathcal{M}, \mu\mathcal{D}^p\right), \left(\mathbb{X}_n, c_n D^p_{\mathbb{X}_n}\right)\right) > \varepsilon\right) \leq e^{-\theta n^\kappa}$$

para n suficientemente grande.

Algo similar vale para Isomap y para Wasserstein empírico.

Convergencia de espacios métricos con medida

$h\colon \mathbb{X} \to \mathbb{Y}$ es una ε-isometría si

- para todo $x, x' \in \mathbb{X}$ vale $|d_{\mathbb{X}}(x, x') - d_{\mathbb{Y}}(h(x), h(x'))| < \varepsilon$ y

Convergencia de espacios métricos con medida

$h\colon \mathbb{X} \to \mathbb{Y}$ es una ε-isometría si

- para todo $x, x' \in \mathbb{X}$ vale $|d_{\mathbb{X}}(x, x') - d_{\mathbb{Y}}(h(x), h(x'))| < \varepsilon$ y
- para todo $y \in \mathbb{Y}$ vale $d_{\mathbb{Y}}(y, h(\mathbb{X})) < \varepsilon$.

Convergencia de espacios métricos con medida

$h\colon \mathbb{X} \to \mathbb{Y}$ es una ε-isometría si

- para todo $x, x' \in \mathbb{X}$ vale $|d_{\mathbb{X}}(x, x') - d_{\mathbb{Y}}(h(x), h(x'))| < \varepsilon$ y
- para todo $y \in \mathbb{Y}$ vale $d_{\mathbb{Y}}(y, h(\mathbb{X})) < \varepsilon$.

Convergencia de espacios métricos con medida

$h\colon \mathbb{X} \to \mathbb{Y}$ es una ε-isometría si

- para todo $x, x' \in \mathbb{X}$ vale $|d_{\mathbb{X}}(x, x') - d_{\mathbb{Y}}(h(x), h(x'))| < \varepsilon$ y
- para todo $y \in \mathbb{Y}$ vale $d_{\mathbb{Y}}(y, h(\mathbb{X})) < \varepsilon$.

Def. (Fukaya '87, Sturm '06) Una sucesión de espacios compactos $\mathcal{X}_n = (\mathbb{X}_n, d_n, \mu_n)$ converge en sentido Gromov-Hausdorff medido (mGH) a $\mathcal{X} = (\mathbb{X}, d, \mu)$ si existen $\varepsilon_n \to 0$ y ε_n-isometrías $h_n\colon \mathbb{X}_n \to \mathbb{X}$ tales que $(h_n)_{\#}(\mu_n) \to \mu$ débilmente.

Consistencia de k-medias con distancias aprendidas

Teorema (G., Jonckheere, Serres, Sued, 2025+)

Si $\mathcal{X}_n = (\mathbb{X}_n, d_n, \mu_n) \to \mathcal{X} = (\mathbb{X}, d, \mu)$ en sentido mGH, entonces para todo $k \geq 1$

$$\max_{A_n \in F_k(\mathcal{X}_n)} \min_{A \in F_k(\mathcal{X})} d_H(h_n(A_n), A) \to 0.$$

Consistencia de k-medias con distancias aprendidas

Teorema (G., Jonckheere, Serres, Sued, 2025+)

Si $\mathcal{X}_n = (\mathbb{X}_n, d_n, \mu_n) \to \mathcal{X} = (\mathbb{X}, d, \mu)$ en sentido mGH, entonces para todo $k \geq 1$

$$\max_{A_n \in F_k(\mathcal{X}_n)} \min_{A \in F_k(\mathcal{X})} d_H(h_n(A_n), A) \to 0.$$

Aprendé bien la distancia y k-medias hace el resto.

¡Gracias!